Report - Analisi Recensioni Hotel di Lusso in Europa (2015-2017)

AUTORE: MARCO DI CERBO

Analisi delle recensioni Booking.com per hotel di lusso in Europa (2015–2017)

Indice

1. Introduzione 2

2. Metodologia di lavoro 3

2.1 Comprensione del dataset e obiettivi 3

2.2 Pulizia e preparazione dei dati 3

2.3 Progettazione schema SQL e caricamento dati 4

2.4 Analisi in Python/Pandas e visualizzazioni 4

3. Risultati principali 5

3.1 Trend temporali delle recensioni (2015–2017) 5

3.2 Profilo per nazionalità dei recensori 6

3.3 Performance delle principali città e hotel 8

3.4 Relazione tra score, lunghezza e contenuto delle recensioni 10

3.5 Correlazioni tra variabili numeriche 12

4. Implicazioni di business e raccomandazioni per il cliente 13

4.1 Mercati di origine prioritari 13

4.2 Posizionamento per destinazione 13

4.3 Gestione delle recensioni e customer experience 14

4.4 Uso strategico delle informazioni per Revenue Management 14

5. Conclusioni 15

6. References 16

1. Introduzione

Questo report presenta i risultati di un progetto di analisi dati condotto su un dataset di recensioni Booking.com relativo a **circa 515.000 recensioni** per **1.493 hotel** situati in Europa, raccolte nel periodo **2015–2017**. L'analisi è stata commissionata con l'obiettivo di fornire insight utili a un cliente interessato a sviluppare strategie di marketing e posizionamento per il segmento degli **hotel di lusso**, con particolare focus sul mercato europeo.

Le recensioni online rappresentano oggi una delle principali fonti di informazione per i viaggiatori e una leva chiave per il posizionamento competitivo delle strutture ricettive. Comprendere volumi, provenienza geografica dei clienti, livelli di soddisfazione e pattern testuali delle recensioni consente ai **Revenue Manager** e ai responsabili marketing di:

- identificare i mercati di origine più rilevanti;
- valutare la performance percepita delle destinazioni e delle singole strutture;
- cogliere segnali ricorrenti nelle esperienze positive e negative;
- calibrare le politiche di prezzo e comunicazione.

L'analisi si concentra su quattro aree principali, che corrispondono alle sezioni "Risultati" e "Conclusioni" del report:

- evoluzione temporale dei volumi di recensioni;
- profilo per nazionalità dei recensori;
- performance delle principali città europee e degli hotel associati;
- relazione tra score, lunghezza e contenuto delle recensioni, con particolare attenzione alle correlazioni tra variabili numeriche.

2. Metodologia di lavoro

2.1 Comprensione del dataset e obiettivi

Il dataset di partenza comprende, per ciascuna recensione, informazioni su:

- hotel (nome, indirizzo, città);
- recensore (nazionalità, numero di recensioni totali sull'hotel, punteggio assegnato);
- testo della recensione (parte positiva, parte negativa);
- variabili derivate (lunghezza recensione, conteggio parole positive e negative, giorni trascorsi dalla recensione rispetto a una data di riferimento);
- metadata temporali (data, anno, mese, combinazione anno-mese).

Sulla base delle istruzioni di progetto, gli obiettivi sono stati declinati in:

1. **Costruzione di un database relazionale** di supporto per interrogazioni flessibili (SQL).
2. **Analisi descrittive ed esplorative** con Python/Pandas, per comprendere pattern e distribuzioni.
3. **Produzione di visualizzazioni** adatte a comunicare i risultati a un pubblico business (line plot, bar chart, box/violin plot, heatmap).

2.2 Pulizia e preparazione dei dati

Le principali attività di pulizia hanno riguardato:

- rimozione o correzione di valori mancanti per campi chiave (lat, lng, città hotel, nazionalità recensore, score);
- creazione di variabili derivate:
    - **Review_Length** come numero di parole o caratteri della recensione;
    - **Review_Year, Review_Month e Review_YearMonth** a partire da **Review_Date** per poter effettuare analisi per un periodo temporale annuale e mensile;
    - **Reviewer_Review_Count,** rinominata a partire dalla colonna **Total_Number_of_Reviews_Reviewer_Has_Given** per maggiore chiarezza e comodità data l'eccessiva lunghezza del nome;

- gestione dei tipi di dato: conversione esplicita di colonne salvate come `object`, in particolare `Review_Date` e `days_since_review`, rispettivamente a formato datetime e a formato numerico, per facilitare le analisi e permettere il calcolo delle correlazioni.

Questa fase ha garantito la coerenza del dataset con lo schema del database SQL e con le esigenze di analisi successive.

2.3 Progettazione schema SQL e caricamento dati

È stato definito uno **schema relazionale** in grado di rappresentare in modo efficiente la relazione tra hotel, recensioni e recensori, con una tabella principale delle recensioni e tabelle di supporto per hotel e altre entità di riferimento.

Sono state predisposte query SQL per:

- calcolare volumi di recensioni per anno, mese e combinazione anno-mese;
- individuare le **top città** per numero di recensioni;
- determinare la **top 10 nazionalità** per volume di recensioni;
- estrarre sottoinsiemi di dati aggregati (es. medie per città, nazionalità, intervalli temporali) da utilizzare in Pandas per la parte di visualizzazione e modellazione.

Questa struttura ha permesso di utilizzare SQL per i passaggi più adatti (aggregazioni, filtri, join) e Pandas per quelli più flessibili (feature engineering, visualizzazioni, analisi esplorativa).

2.4 Analisi in Python/Pandas e visualizzazioni

Una volta creati i dataset aggregati, l'analisi è proseguita con:

- calcolo di metriche descrittive (media, mediana, distribuzioni) su **reviewer_score**, lunghezza recensioni e conteggi di parole positive/negative;
- costruzione di grafici in **Plotly** per:
    - trend temporali (line plot di recensioni per mese e anno);
    - bar chart delle top nazionalità e delle top città per numero di recensioni;
    - distribuzioni di score (box plot per top nazionalità);
    - distribuzione della lunghezza recensioni per categorie di score (istogrammi e violin plot);
    - score medio per città (bar chart);

- **heatmap di correlazione** tra variabili numeriche (score, conteggi parole, days since review).

Le visualizzazioni sono state esportate in formato immagine per l'inserimento nel presente report.

3. Risultati principali

3.1 Trend temporali delle recensioni (2015–2017)

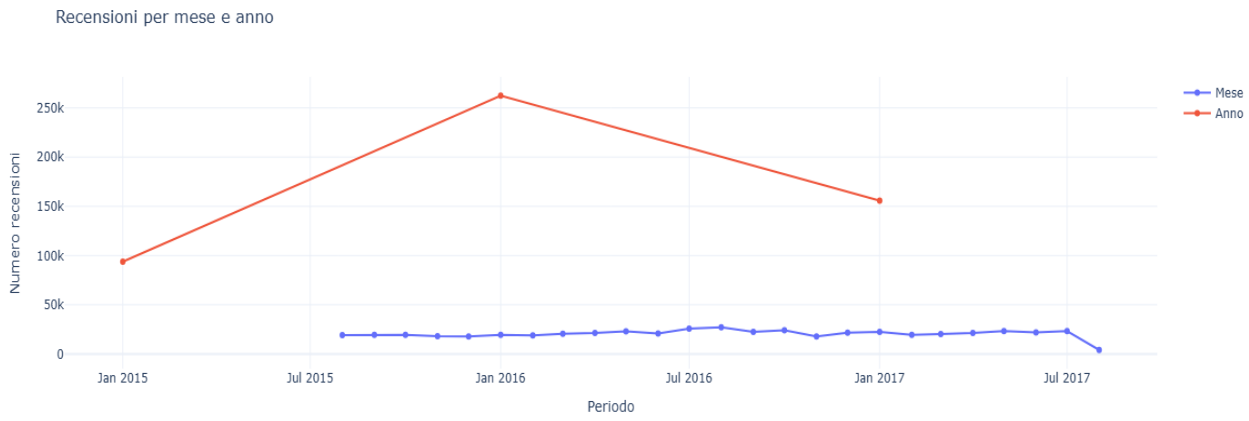

Il grafico delle recensioni per mese e anno evidenzia i seguenti elementi chiave:

- Il volume annuale di recensioni **cresce tra 2015 e 2016**, con il **2016** che rappresenta l'anno con il numero più alto di recensioni nel periodo analizzato.
- Nel **2017** il volume appare inferiore, ma i dati disponibili sono parziali (non coprono l'intero anno), pertanto i confronti tra anni devono essere interpretati con cautela.
- A livello mensile, i volumi risultano **relativamente stabili**, con oscillazioni contenute e alcuni mesi leggermente più attivi, verosimilmente legati alle stagionalità tipiche del turismo europeo (alta stagione primaverile/estiva).

Per il cliente ciò suggerisce che, nel periodo analizzato, la **propensione a recensire** gli hotel su Booking.com è in crescita, in linea con la maggiore centralità delle piattaforme online nelle decisioni di acquisto di soggiorni in strutture di fascia medio-alta e lusso.

3.2 Profilo per nazionalità dei recensori

Top 10 nazionalità per numero di recensioni

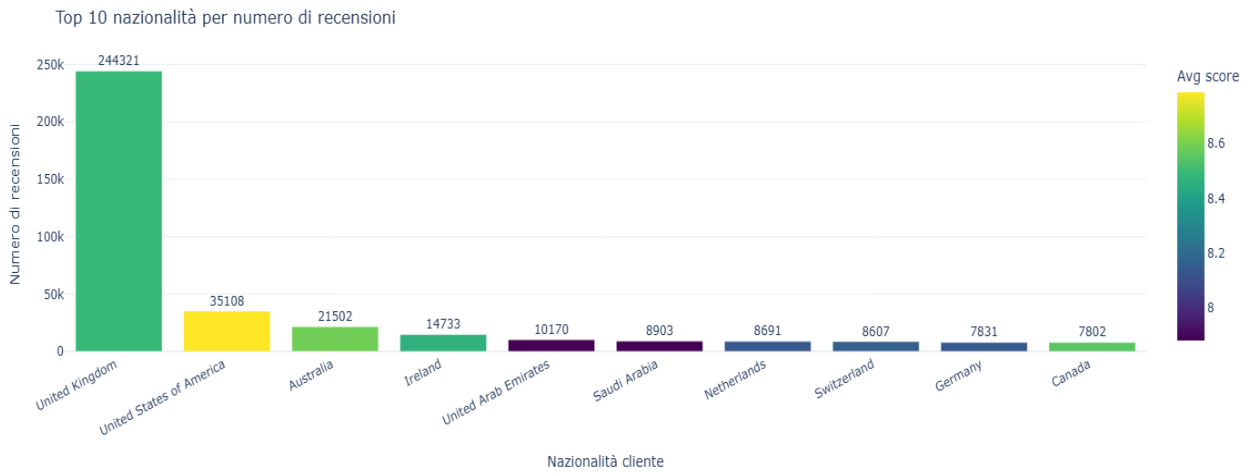

Dal bar chart emergono i seguenti punti:

- I clienti provenienti dal **Regno Unito** rappresentano di gran lunga il gruppo più numeroso, con un volume di recensioni nettamente superiore a tutte le altre nazionalità.
- Gli **Stati Uniti** e l'**Australia** seguono a distanza, ma restano tra i mercati più rilevanti per numero di recensioni.
- Le altre nazionalità in top 10 (tra cui Emirati Arabi Uniti, Arabia Saudita, Paesi Bassi, Svizzera, Germania, Canada) mostrano volumi significativi ma decisamente più contenuti rispetto al Regno Unito.
- Lo score medio associato alle diverse nazionalità, rappresentato dalla scala colore del grafico, risulta complessivamente **simile e su valori alti**, senza grandi distanze tra i gruppi, segno di una soddisfazione mediamente elevata e abbastanza uniforme.

Per un hotel di lusso in Europa, questi risultati indicano che:

- il **mercato UK** è un bacino chiave sia in termini di domanda sia di visibilità online;
- mercati extra-europei come **USA, Australia e paesi del Golfo** generano comunque un volume non trascurabile di recensioni, quindi meritano campagne di comunicazione e offerte dedicate.

Distribuzione dello score per le principali nazionalità

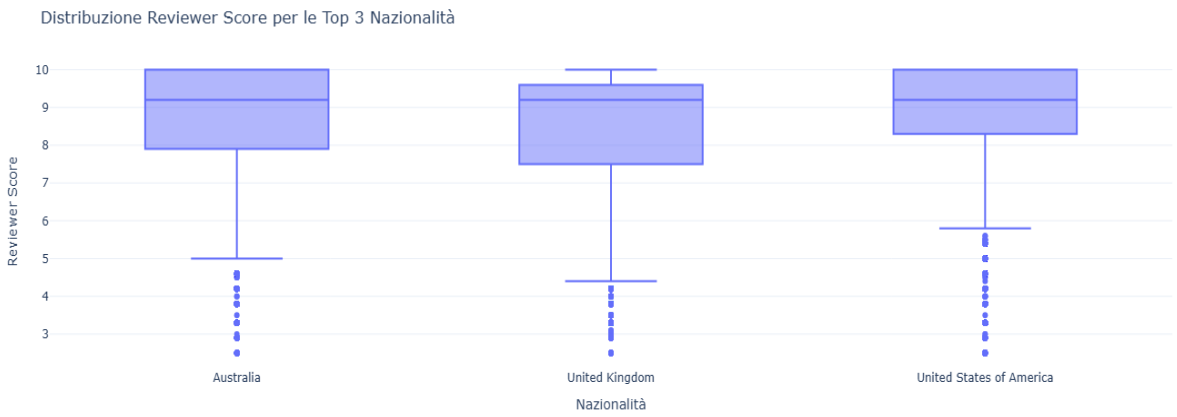

La distribuzione del **reviewer_score** per le tre nazionalità più rappresentate (Australia, Regno Unito, Stati Uniti) mostra:

- score medi **molto elevati e simili** tra i tre gruppi, con la maggior parte delle recensioni concentrate nella fascia alta della scala di valutazione;
- alcune differenze nella **dispersione**: in alcuni casi il Regno Unito presenta una coda leggermente più estesa verso punteggi più bassi, suggerendo una maggiore variabilità nelle esperienze percepite;
- la presenza di outlier a punteggio basso, ma in numero contenuto.

In sintesi, i recensori dei mercati anglofoni esprimono in media valutazioni **positivamente elevate**, risultando quindi **clienti tendenzialmente generosi nello score**, pur con una maggiore severità in specifiche situazioni (outlier negativi).

3.3 Performance delle principali città e hotel

Top città per numero di recensioni

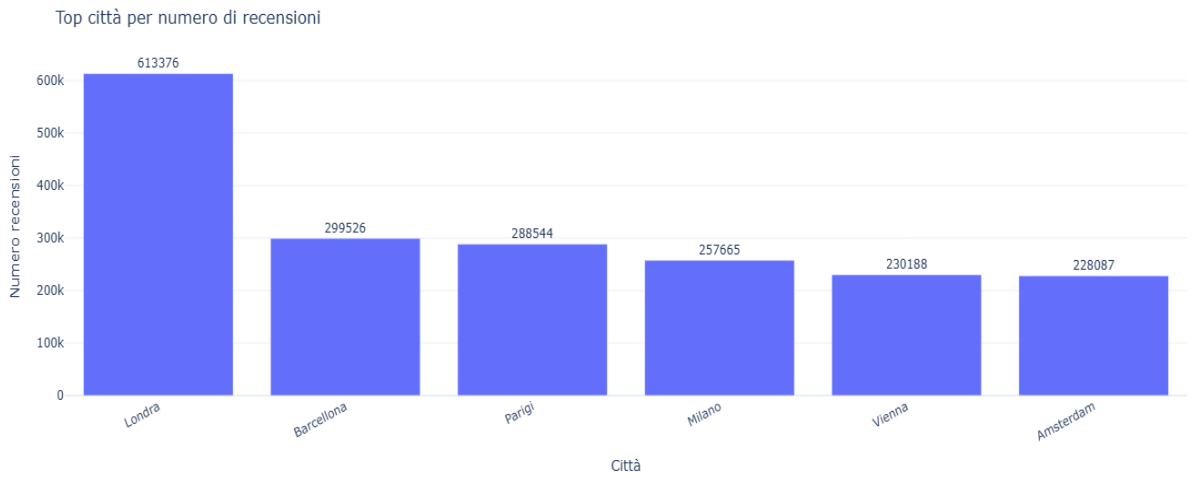

Il grafico delle top città per numero di recensioni evidenzia

- **Londra** come città nettamente dominante per volume di recensioni, con un numero di commenti che supera abbondantemente le altre città analizzate.
- **Barcellona** e **Parigi** al secondo e terzo posto, con volumi comunque molto elevati ma di circa la metà rispetto a Londra.
- **Milano, Vienna e Amsterdam** completano il gruppo di città con volumi importanti e relativamente simili tra loro.

Londra emerge quindi come **hub principale del campione**, sia per domanda sia per visibilità, e rappresenta un benchmark naturale per il posizionamento degli hotel di lusso in altre capitali europee.

Score medio per città

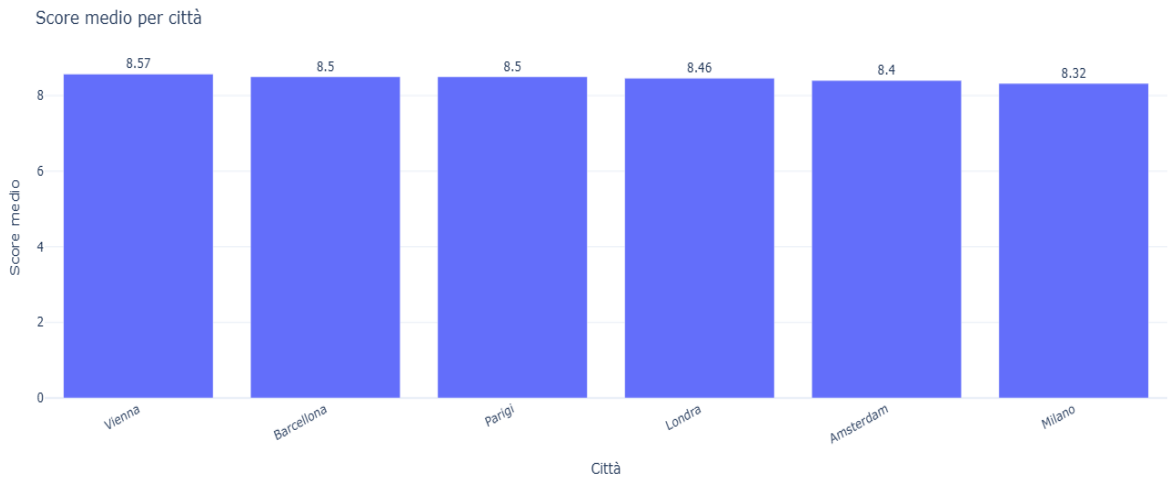

Quando si analizza lo **score medio** delle principali città, il quadro si fa più sfumato:

- le città considerate presentano **score medi molto simili**, tutti in una fascia di punteggio elevata (intorno a 8,3–8,6);
- **Vienna** risulta la città con lo score medio leggermente più alto;
- **Barcellona e Parigi** mostrano score medi molto vicini a Vienna, seguite a brevissima distanza da **Londra**;
- **Amsterdam e Milano** presentano score medi leggermente inferiori, ma sempre in un range che indica una **buona soddisfazione complessiva**.

Questi risultati suggeriscono che, almeno per il campione analizzato, le principali destinazioni europee di interesse turistico presentano **standard di qualità percepita abbastanza omogenei**, con **Vienna, Barcellona e Parigi** leggermente avanti. Per un hotel di lusso, ciò implica che il differenziale competitivo non è tanto nel punteggio medio assoluto, quanto nella capacità di emergere all'interno di mercati complessivamente già ben valutati.

3.4 Relazione tra score, lunghezza e contenuto delle recensioni

Distribuzione della lunghezza recensione per categoria di score – istogramma

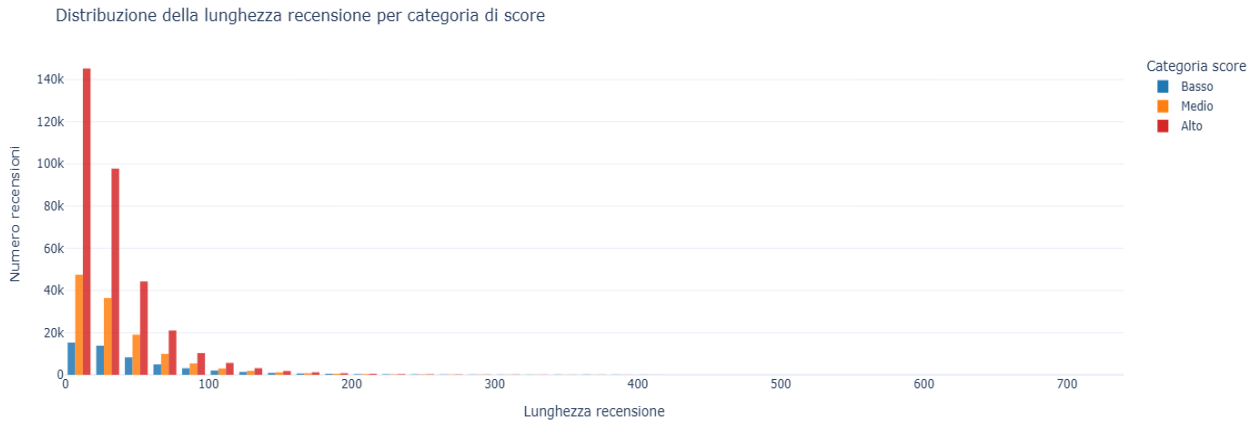

Dal grafico di distribuzione della lunghezza recensione per categorie di score (es. Basso, Medio, Alto) si osserva:

- la maggior parte delle recensioni, indipendentemente dalla categoria di score, è **relativamente corta**, concentrata in classi di lunghezza basse;
- le recensioni associate a **score alti** risultano però **più numerose anche alle lunghezze maggiori**, suggerendo che i clienti soddisfatti tendono più spesso a dedicare qualche parola in più alla descrizione dell'esperienza positiva;
- le recensioni con **score basso** sono meno frequenti e tendenzialmente più brevi, ma con alcune osservazioni più lunghe che potrebbero contenere dettagli importanti su criticità specifiche.

In termini pratici, ciò indica che le recensioni molto brevi non sono necessariamente negative; al contrario, una parte consistente di recensioni positive può essere sintetica. Tuttavia, le recensioni **più lunghe** sono spesso associate a una motivazione forte (soddisfazione o insoddisfazione) e meritano un'attenzione particolare nella lettura qualitativa.

Distribuzione della lunghezza recensione per categoria di score – violin plot

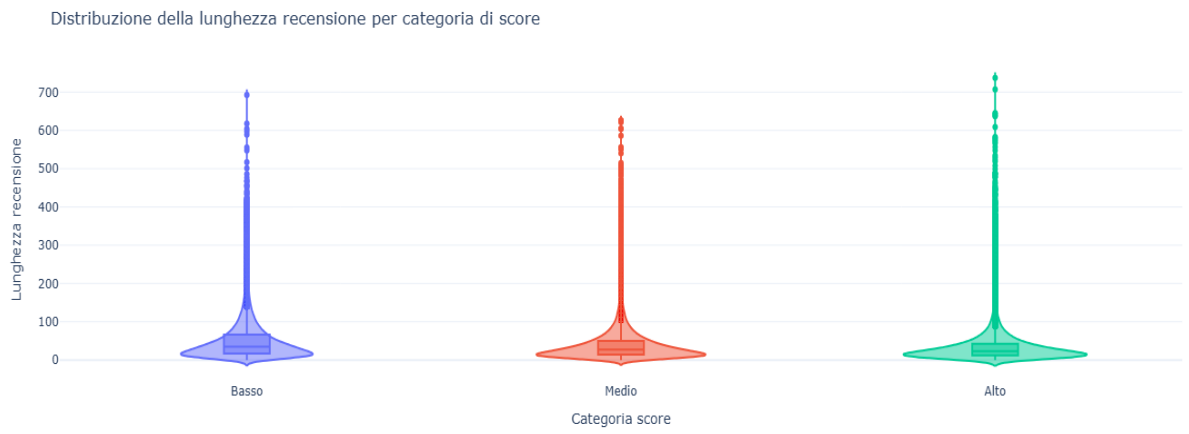

Il violin plot permette di visualizzare meglio la distribuzione completa della lunghezza recensione per le tre categorie di score (Basso, Medio, Alto):

- le tre distribuzioni risultano **simili nella forma di base**, con forte concentrazione di recensioni brevi e code verso lunghezze molto elevate;
- la variabilità aumenta soprattutto nella parte alta della distribuzione (recensioni molto lunghe), ma **senza differenze nette** tra le categorie di score: tutte e tre mostrano la presenza di recensioni eccezionalmente lunghe;
- nel complesso, il grafico conferma che la **lunghezza della recensione non è di per sé un indicatore univoco di soddisfazione**, ma può contribuire a identificare i casi più estremi (molto soddisfatti o molto insoddisfatti).

Per il cliente, questo suggerisce che eventuali sistemi di monitoraggio automatico dovrebbero combinare **lunghezza del testo** e **sentiment** (es. score, parole chiave positive/negative) piuttosto che usare un solo indicatore.

3.5 Correlazioni tra variabili numeriche

Heatmap delle correlazioni

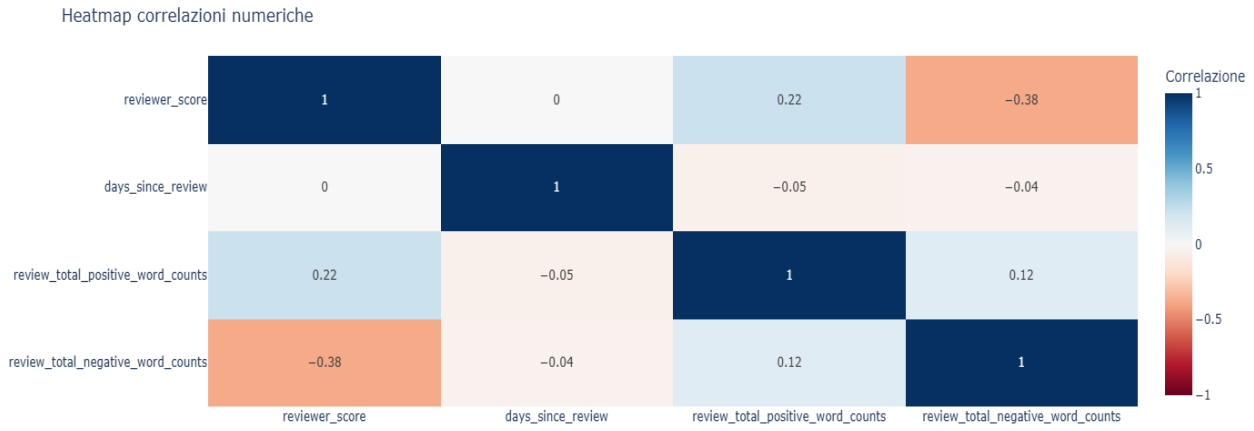

La heatmap delle correlazioni numeriche considera le seguenti variabili:

- `reviewer_score` (punteggio assegnato dal cliente);
- `days_since_review` (tempo trascorso dalla recensione);
- `review_total_positive_word_counts` (parole positive);
- `review_total_negative_word_counts` (parole negative).

I principali risultati sono:

- nel complesso, le correlazioni sono **deboli o moderate**, il che indica che nessuna variabile spiega in modo dominante le altre;
- `reviewer_score` presenta una **correlazione negativa moderata** con `review_total_negative_word_counts`: all'aumentare delle parole negative, il punteggio tende a diminuire, come atteso;
- la correlazione tra `reviewer_score` e `review_total_positive_word_counts` è **positiva ma debole**, segno che più parole positive tendono ad associarsi a score più alti, ma non in modo fortemente lineare;
- `days_since_review` mostra **correlazioni prossime allo zero** con le altre variabili, suggerendo che la distanza temporale non ha un impatto diretto e forte su score o conteggi di parole;

- la correlazione tra `review_total_positive_word_counts` e `review_total_negative_word_counts` è molto bassa, il che indica che il volume di termini positivi non è strettamente legato a quello dei termini negativi nella stessa recensione.

Questa analisi conferma che lo **score finale** è coerente con il contenuto testuale (più parole negative → punteggio più basso, più parole positive → punteggio leggermente più alto), ma anche che le recensioni contengono una certa complessità che non può essere sintetizzata in una sola variabile.

4. Implicazioni di business e raccomandazioni per il cliente

Sulla base dei risultati descritti, si possono trarre alcune implicazioni operative per un cliente attivo nel segmento degli **hotel di lusso in Europa**.

4.1 Mercati di origine prioritari

- Il **Regno Unito** è il mercato più rilevante per volume di recensioni: gli hotel che desiderano rafforzare la propria presenza nel segmento lusso devono considerare il mercato UK come priorità per campagne di marketing, partnership con agenzie e ottimizzazione delle pagine in lingua inglese rivolte a questo pubblico.
- **Stati Uniti, Australia e paesi del Golfo** (Emirati Arabi Uniti, Arabia Saudita) rappresentano mercati extra-europei ad alto potenziale, in grado di generare un flusso consistente di recensioni e quindi di visibilità online.
- Data la **generosità media nello score** da parte dei clienti UK e anglofoni, investire nella loro soddisfazione può portare a un ritorno particolarmente elevato in termini di reputazione digitale.

4.2 Posizionamento per destinazione

- Le principali città europee analizzate (Londra, Barcellona, Parigi, Milano, Vienna, Amsterdam) presentano **score medi tutti elevati e vicini**, segno di una concorrenza su standard qualitativi comparabili.
- **Vienna, Barcellona e Parigi** risultano leggermente avanti in termini di punteggio medio, mentre Londra è leader per volume di recensioni: ciò suggerisce che Londra combina **alta visibilità** con una **buona qualità percepita**, diventando un benchmark di riferimento.
- Per un nuovo hotel di lusso che desideri entrare in uno di questi mercati, la strategia dovrebbe prevedere:

- chiari obiettivi di punteggio minimo (es. mantenersi sopra 8,5) per allinearsi o superare la media di destinazione;
- azioni di gestione dell'esperienza cliente mirate a trasformare la soddisfazione in **recensioni numerose e dettagliate**.

4.3 Gestione delle recensioni e customer experience

- Le recensioni **molto brevi** sono frequenti anche tra quelle positive: è quindi importante rendere il processo di recensione semplice e veloce, in modo da non scoraggiare chi intende lasciare solo pochi commenti sintetici.
- Le recensioni **più lunghe**, indipendentemente dallo score, tendono a contenere dettagli rilevanti su aspetti dell'esperienza (servizio, pulizia, posizione, colazione, ecc.): si raccomanda di monitorarle con particolare attenzione, anche attraverso sistemi di alert o analisi testuale automatica.
- L'associazione tra **parole negative** e score più bassi conferma che la gestione proattiva dei reclami (es. risposta rapida, soluzioni offerte, compensazioni mirate) può contribuire a mitigare l'impatto di esperienze negative sulla reputazione complessiva.

4.4 Uso strategico delle informazioni per Revenue Management

- L'andamento crescente dei volumi di recensioni tra 2015 e 2016 indica una **maggiore esposizione al giudizio online**: politiche di prezzo e promozioni devono tenere conto non solo dell'occupazione, ma anche della salute della reputazione digitale.
- La combinazione di **volumi elevati e score medi alti** in destinazioni come Londra, Barcellona, Parigi e Vienna suggerisce che, in presenza di una buona reputazione, è possibile sostenere **strategie di pricing premium**, soprattutto nei periodi di alta domanda.
- La segmentazione per nazionalità e città consente di costruire **offerte mirate** (es. pacchetti su misura per turisti UK o americani, comunicazione in lingua, partnership con operatori locali) massimizzando l'impatto su segmenti che hanno dimostrato maggiore propensione a recensire e a valutare positivamente l'esperienza.

5. Conclusioni

L'analisi del dataset Booking.com 2015–2017 fornisce una serie di evidenze utili per chi opera nel settore degli **hotel di lusso in Europa**:

- il volume di recensioni è in crescita e rende la reputazione online un asset sempre più centrale, con il **2016** come anno di picco nel periodo considerato;
- il **Regno Unito** emerge come principale mercato di origine delle recensioni, seguito da altri Paesi anglofoni e da mercati extra-europei ad alto potenziale (USA, Australia, paesi del Golfo);
- le principali destinazioni europee analizzate (Londra, Barcellona, Parigi, Milano, Vienna, Amsterdam) presentano **standard qualitativi percepiti elevati e simili**, con **Vienna, Barcellona e Parigi** leggermente avanti in termini di score medio, mentre **Londra** è leader assoluta per numero di recensioni;
- la relazione tra score, lunghezza e contenuto delle recensioni mostra che i testi più lunghi spesso riflettono esperienze particolarmente positive o negative e che l'aumento delle parole negative è coerentemente associato a punteggi più bassi;
- le correlazioni tra variabili numeriche sono in generale deboli o moderate, a conferma della complessità dei comportamenti dei clienti e della necessità di combinare **indicatori quantitativi e qualitativi** per una lettura completa delle recensioni.

Per il cliente, i principali messaggi operativi possono essere riassunti come segue:

1. **Londra è leader in termini di visibilità e qualità percepita**, e rappresenta un benchmark naturale per il posizionamento degli hotel di lusso nelle altre capitali europee.
2. I **recensori provenienti dal Regno Unito e da altri Paesi anglofoni** risultano in media soddisfatti e tendenzialmente "generosi" nello score, rendendoli un target prioritario per campagne di fidelizzazione e cura della customer experience.
3. Le recensioni online, soprattutto quelle più articolate, costituiscono una **miniera di insight**: combinarne l'analisi quantitativa con tecniche di text mining (non oggetto di questo progetto ma suggerite come evoluzione) permetterebbe di individuare con ancora maggiore precisione i driver di soddisfazione e insoddisfazione.
4. In un contesto competitivo in cui le destinazioni di lusso europee presentano punteggi medi già elevati, la differenza si gioca su **dettagli di servizio, coerenza dell'esperienza e gestione proattiva delle recensioni**, più che su scarti numerici minimi nello score.

Il presente report offre quindi una base solida per decisioni informate di **Revenue Management**, marketing e posizionamento strategico, e può essere ulteriormente arricchito da analisi successive su

segmenti specifici (tipologia di viaggio, fascia di prezzo, servizi accessori) e da integrazioni con altre fonti dati interne dell'hotel o della catena alberghiera.

References

1. https://www.kaggle.com/datasets/jiashenliu/515k-hotel-reviews-data-in-europe/data